Herbiers & CrossViT : Segmentation, Pondération par Patch et Interprétabilité

FILALI Amine
JOUDI Haroun

Dr. Youcef Sklab

2025/2026

Plan de Présentation

1. Introduction & Contexte
2. Objectifs du Projet
3. Données & Prétraitement
4. Environnement et paramètres d'entraînement
5. Méthodologie & Architecture
6. Améliorations proposées
7. Interprétabilité & Optimisation
8. Conclusion & perspectives

2

Introduction & Contexte

- Analyse automatisée de spécimens d'herbiers numérisés
- Présence de bruit visuel important :
  - étiquettes
  - règles
  - codes-barres
- Ces éléments perturbent l'apprentissage des réseaux de neurones
- Exploitation de paires d'images :
  - vue complète (image bruitée)
  - vue segmentée (plante isolée)
- Objectif :
  - guider l'attention du modèle
  - se concentrer sur les structures botaniques

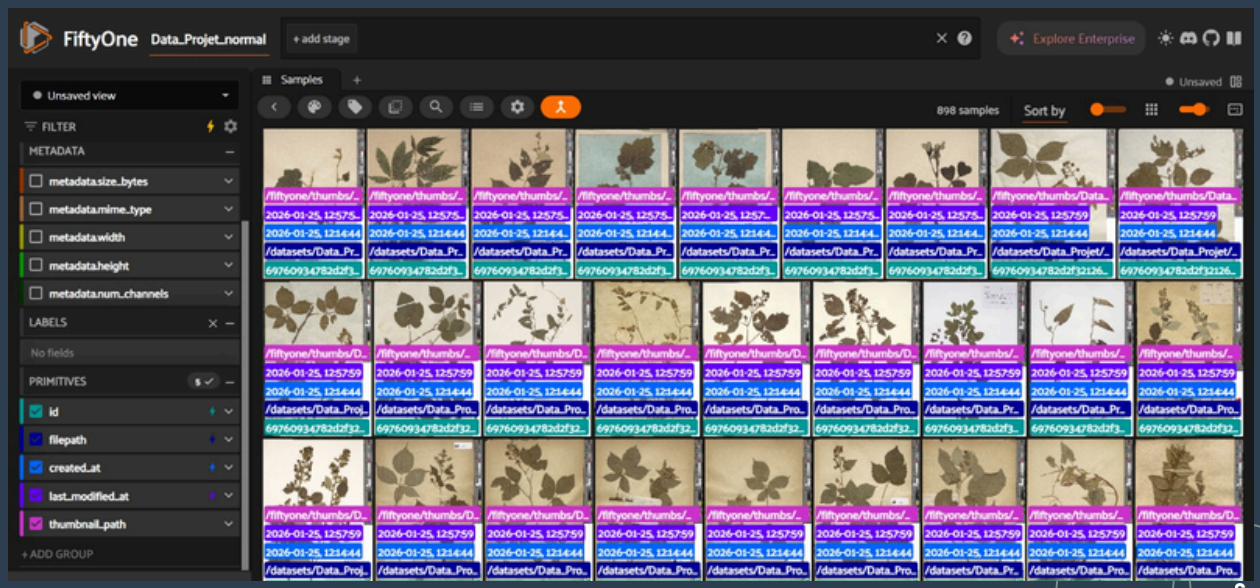
Objectifs du Projet

Le projet est structuré autour de cinq objectifs principaux :

- O1 – Initialisation : évaluer les performances de base du modèle CrossViT selon différentes configurations d'entrée.
- O2 – Architecture : proposer une variante du CrossViT avec deux branches symétriques à même résolution.
- O3 – Pondération : intégrer une pondération par patch guidée par la densité de la plante.
- O4 – Analyse : étudier le comportement du modèle via des outils d'interprétabilité (Attention Rollout et IoU).
- O5 – Optimisation : améliorer l'apprentissage en intégrant une perte basée sur l'IoU.

Données & Prétraitement

- Dataset Herbiers : 898 entrées (initialement 2000)
- Composition de chaque entrée :
  - image non segmentée (planche complète)
  - image segmentée (plante isolée)
  - label : présence / absence d'épines
- Stockage des données :
  - base de données hébergée sur un serveur dédié
  - centralisation des images et labels
- Accès aux données :
  - via une API
  - utilisée par le serveur d'entraînement


FiftyOne
Data_Projet_normal
+ add stage
Explore Enterprise
Samples
Unsaved view
FILTER
METADATA
metadata.size_bytes
metadata.mime_type
metadata.width
metadata.height
metadata.num_channels
LABELS
No fields
PRIMITIVES
id
filepath
created_at
last_modified_at
thumbnail_path
+ ADD GROUP
898 samples
Sort by
Unsaved

6

Données & Prétraitement

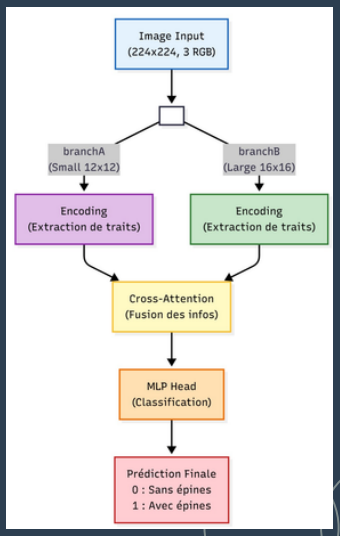
- Prétraitement des images :
  - redimensionnement en 224 × 224
  - normalisation
  - découpage en patchs
- Alignement spatial des patchs :
  - image originale / image segmentée
  - indispensable pour la Cross-Attention

Environnement et paramètres d'entraînement

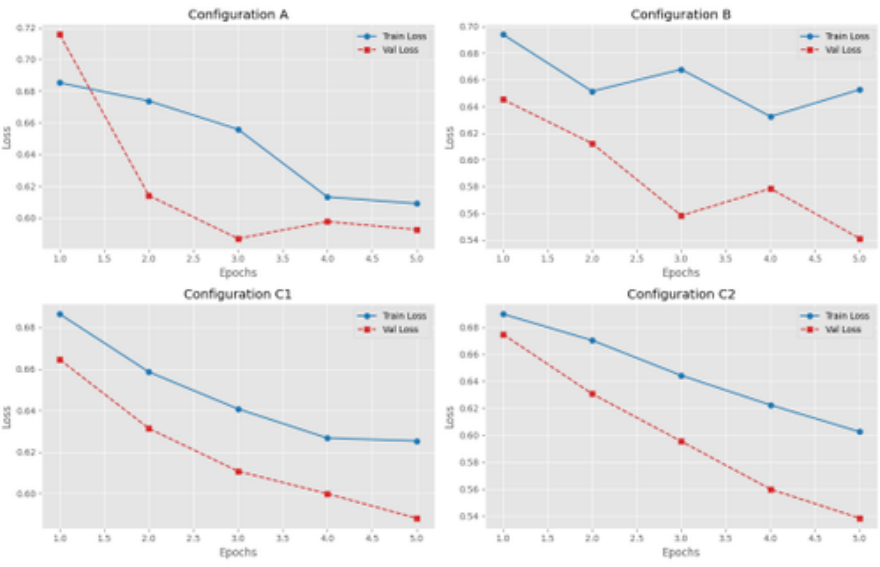
- Architecture de calcul :
  - serveur d'entraînement distinct du serveur de données
- Ressources matérielles :
  - GPU NVIDIA A100 / H100
- Optimisation du calcul :
  - précision mixte (AMP)
- Paramètres d'entraînement :
  - Epoques : 5
  - Batch size : 64
  - profondeur du modèle : 8
  - nombre de têtes d'attention : 8
  - MLP ratio : 4
- Entraînement :
  - récupération des données via l'API
  - calcul intensif effectué sur GPU

Méthodologie & Architecture

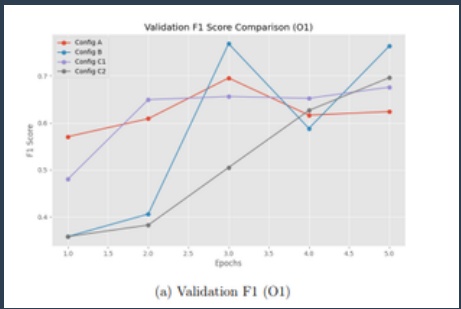
- Base du modèle : Vision Transformer (ViT)
- Architecture CrossViT à deux branches :
  - branche Small :
    - patchs fins (12 × 12)
    - embedding dimension : 192
  - branche Large :
    - patchs plus larges (16 × 16)
    - embedding dimension : 384
- Fusion des informations par Cross-Attention
- Configurations évaluées :
- Mode A : image non segmentée
- Mode B : image segmentée
- C1 : segmentées → Large, non segmentées → Small
- C2 : segmentées → Small, non segmentées → Large.



9



(b) Validation Loss (O1)



(a) Validation F1 (O1)

Configuration	Acc (Val)	F1 (Best Val)	Val Loss
Mode A	70.56 %	0.6954	0.5869
Mode B	77.22 %	**0.7685**	0.5582
Mode C1	68.89 %	0.6760	0.5881
Mode C2	71.11 %	0.6961	0.5384

TABLE 1 – Synthèse des résultats O1. Le **Mode B** domine cette première phase.

Améliorations proposées

- O2 – Architecture Iso-Scale :
  - deux branches strictement identiques
  - même taille de patch
  - même dimension d'embedding
  - objectif : faciliter l'alignement des caractéristiques
- O3 – Pondération par Patch :
  - calcul du ratio de plante par patch
  - pondération guidée par le masque de segmentation

Le poids w_p du patch est défini par une fonction puissance :

$$w_p = f(r_p) = (r_p + \epsilon)^{\gamma} \quad \text{avec } \gamma = 0.5$$

Ce poids est propagé aux patchs correspondants de l'image non-segmentée.

Configuration	Acc (Val)	F1 (Best Val)	Val Loss
Mode B (Best O1)	77.22 %	0.7685	0.5582
Mode O2 (Iso-Scale)	**80.00 %**	**0.7981**	**0.4950**

TABLE 2 – Comparaison Best O1 vs O2.

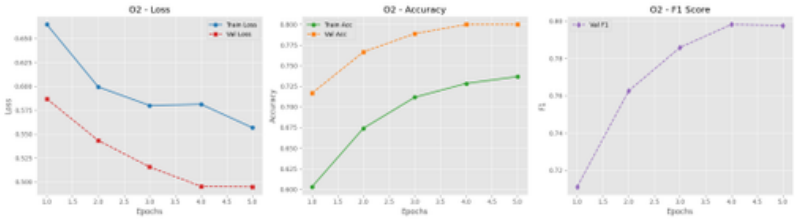
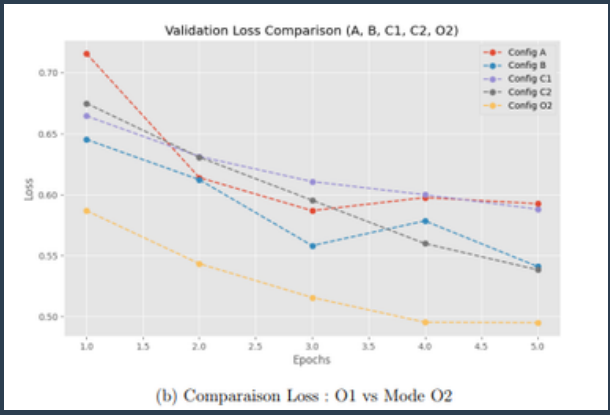


FIGURE 3 – Détail O2 : Loss Accuracy et F1 Score.

12



(a) Comparaison F1-Score : O1 vs Mode O2



(b) Comparaison Loss : O1 vs Mode O2

13

Interprétabilité & Optimisation

- O4 – Interprétabilité :
  - utilisation de l'Attention Rollout
  - visualisation des cartes d'attention
  - analyse de la localisation de l'attention
- IoU (Intersection over Union) :
  - mesure du recouvrement entre :
    - carte d'attention du modèle
    - segmentation réelle de la plante
- O5 – Optimisation :
  - nous ajoutons un terme de pénalité à la Loss standard

$$Loss = L_{Cls} + \lambda \cdot (1 - IoU)$$

avec λ = 0,1
Cela force le modèle à aligner son attention sur la plante.

Configuration	Acc (Val)	F1 (Best Val)	Val Loss
O2 (Sans IoU)	80.00 %	0.7981	0.4950
O5 (Avec IoU)	**80.56 %**	**0.8039**	**0.4779**

TABLE 3 – Comparaison O2 vs O5.

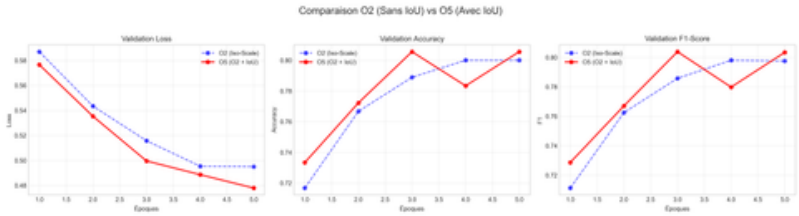
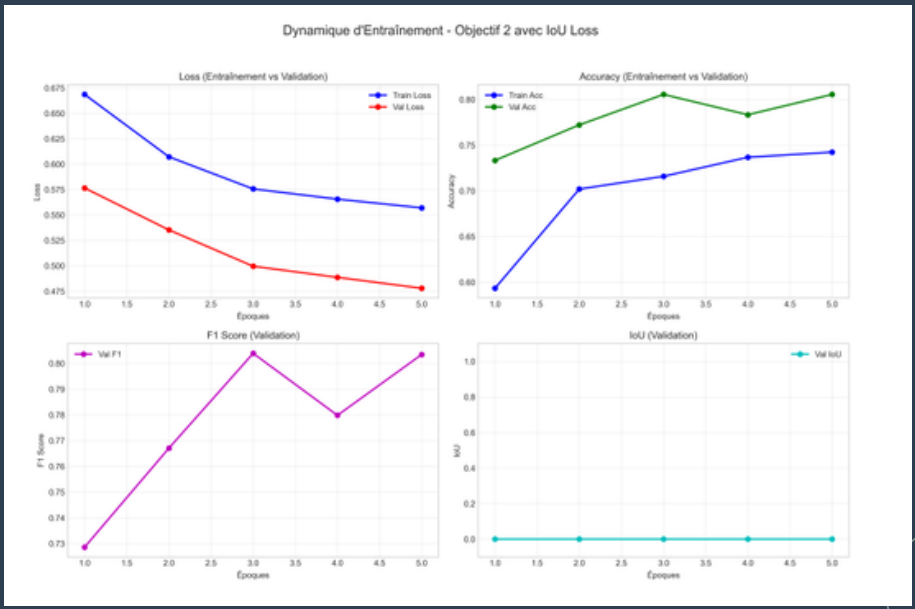


FIGURE 5 – Comparaison directe des courbes d'apprentissage : O2 (Bleu) vs O5 (Rouge).


Dynamique d'Entraînement - Objectif 2 avec IoU Loss
Loss (Entraînement vs Validation)
Train Loss
Val Loss
Loss
Époques
Accuracy (Entraînement vs Validation)
Train Acc
Val Acc
Accuracy
Époques
F1 Score (Validation)
Val F1
F1 Score
Époques
IoU (Validation)
Val IoU
IoU
Époques

Conclusion & perspectives

- La segmentation joue un rôle central dans la performance
- Les architectures multi-branches sont efficaces
- La pondération par patch améliore l'interprétabilité
- La régularisation IoU :
  - améliore les performances
  - rend les décisions plus explicables

- Perspectives :
- segmentation automatique
- autres métriques d'attention
- extension à d'autres datasets botaniques

13

Merci pour votre Attention

14